# Documentação do TP2 - Banco de dados

Integrantes da equipe: Guilherme Kauê, Kaio Carvalho, Washington

## Estrutura de cada arquivo de dados e índices

- 1. **Arquivo de dados**: cada linha contém os seguintes campos, nesta ordem: ID, Titulo, Ano, Autores, Citacoes, Data Atualizacao, Snippet.
  - O acesso é feito por leitura sequencial (programa findrec) ou por offset (programas seek1 e seek2).
  - O tamanho do bloco lógico usado é de 4096 bytes.
  - Cada programa calcula blocos lidos e blocos totais chamando bytes\_para\_blocos() (definido em util.hpp).
- Índice primário: Armazena pares (ID, offfset) em binário, onde ID é um inteiro de 4 bytes e offset é a posição no arquivo de dados em 8 bytes, ocupando um total de 12 bytes.
  - A busca é realizada por varredura linear em disco (seek1.cpp).
- Índice secundário: Armazena pares (Titulo, offset) em binário, com o comprimento do título contendo 4 bytes juntamente com o offset do registro.
  A busca sequencial é feita pelo título exato.
- 4. **Arquivo de índice B+**: a classe ArvoreBMais representa um índice persistente simples.

Implementação reduzida, ou seja, grava pares (chave, posição) de forma sequencial em arquivo binário.

# Quais fontes formam cada programa

- 1. **upload:** upload.cpp, registro.cpp, util.cpp
- 2. **findrec**: findrec.cpp, registro.cpp, util.cpp
- 3. seek1: seek1.cpp, registro.cpp, util.cpp
- 4. **seek2:** seek2.cpp, registro.cpp, util.cpp
- 5. **Estruturas auxiliares:** hashing\_estatico.cpp, arvore\_bmais.cpp

## As funções que cada fonte contém e o papel de cada uma delas

## 1. upload.cpp

main(): executa o comando upload <arquivo.csv>, cria o diretório data/db + arquivos, lê cada linha do csv, converte em registro, escreve no arquivo de dados e atualiza os índices primário e secundário.

### 2. findrec.cpp

main(): busca direta no arquivo de dados, recebe id como argumento, lê sequencialmente dados.csv, converte linhas em registro e compara o id; calcula blocos lidos e totais.

#### 3. seek1.cpp

main(): busca por id via índice primário, lê indice\_primario.dat até encontrar o id correspondente, usa o offset armazenado para buscar, reconstrói o registro.

#### 4. seek2.cpp

main(): busca por título via índice secundário,lê indice\_secundario.dat, compara o título buscado e se for igual, lê o registro correspondente.

#### 5. hashing estatico.cpp

hashingEstatico(const std::string & arquivo, int qtd, int tam): Inicializa o hashing com arquivo, número de buckets e tamanho.

int funcao\_hash(int chave): calcula chave % qtd\_buckets.

void inserir(const Registro &r): Adiciona registro no arquivo binário.

Registro buscar(int chave): Percorre o arquivo e retorna o registro correspondente.

#### 6. arvore\_bmais.cpp

ArvoreBMais::ArvoreBMais(const std::string &arquivo, int o): Cria arquivo binário para a árvore.

void inserir(int chave, long posicao): adiciona par chave, posição no arquivo. long buscar(int chave): busca linear no arquivo, retorna a posição ou -1.

### 7. registro.cpp

std::vector<char> Registro::serializar() const: Serializa o registro em bytes (com prefixos de tamanho e big endian).

Registro Registro::desserializar\_from\_buffer(const char\* buf, size\_t size): Reconstrói o registro a partir do buffer binário.

Funções auxiliares: write\_u32, write\_i64, read\_u32, read\_i64: manipulam tipos binários fixos.

#### 8. util.cpp

std::vector<std::string> dividir\_csv(const std::string &linha\_inicial, std::istream \*stream\_restante): Divide uma linha CSV em campos, respeitando aspas duplas e quebras de linha.

Registro campos\_para\_registro(const std::vector<std::string> &campos): Converte um vetor de campos em struct Registro.

std::string registro\_para\_csvline(const Registro &r): Serializa o registro para formato CSV.

long bytes\_para\_blocos(long bytes, long tam\_bloco): Calcula o número de blocos a partir de bytes.

Divisão de tarefas – o que cada um fez

**Guilherme Kaue**: fez os seguintes códigos: upload.cpp, findrec.cpp, seek1.cpp, seek2.cpp, fez toda a documentação.

**Kaio Carvalho:** fez os seguintes códigos: hashing\_estatico.cpp, arvore\_bmais.cpp, registro.cpp, util.cpp, fez todos os códigos hpp.

**Washington:** revisou o repositório e fez os testes dos programas, sugerindo algumas mudanças.